

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ  
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук  
Образовательная программа «Прикладная математика и информатика»

**КУРСОВАЯ РАБОТА**

**Исследовательский проект на тему:**

**Применение подходов физически информированного машинного обучения для  
предсказания свойств материала в лазерных аддитивных технологиях**

**Выполнил студент:**

группы #БПМИ234, 2 курса                      Давидюк Тимофей Владимирович

**Проверен руководителем проекта:**

Дубров Александр Владимирович  
Научный сотрудник  
НИЦ «Курчатовский институт»

# Содержание

|  |           |
|--|-----------|
| <b>Аннотация</b>                                       | <b>4</b>  |
| <b>1 Описание предметной области</b>                   | <b>5</b>  |
| <b>2 Анализ текущих проблем</b>                        | <b>5</b>  |
| 2.1 Физически-ориентированные методы . . . . .         | 5         |
| 2.2 Методы, основанные на данных . . . . .             | 6         |
| <b>3 Обзор датасета</b>                                | <b>7</b>  |
| 3.1 Введение . . . . .                                 | 7         |
| 3.1.1 Контекст исследования . . . . .                  | 7         |
| 3.1.2 Ценность датасета . . . . .                      | 7         |
| 3.2 Экспериментальная методология . . . . .            | 7         |
| 3.2.1 Производственный процесс . . . . .               | 7         |
| 3.2.2 Стратегии построения . . . . .                   | 8         |
| 3.3 Структура данных . . . . .                         | 8         |
| 3.3.1 Иерархия хранения . . . . .                      | 8         |
| 3.3.2 Форматы данных . . . . .                         | 9         |
| 3.4 Детальный анализ параметров . . . . .              | 9         |
| 3.4.1 Технологические параметры . . . . .              | 9         |
| 3.4.2 Механические свойства . . . . .                  | 10        |
| <b>4 Постановка задачи и актуальность исследования</b> | <b>10</b> |
| <b>5 Процесс обучения модели</b>                       | <b>10</b> |
| 5.1 Методы конструирования признаков . . . . .         | 10        |
| 5.1.1 Временные характеристики процесса . . . . .      | 10        |
| 5.1.2 Кинематические параметры . . . . .               | 11        |
| 5.1.3 Накопленные эффекты . . . . .                    | 11        |
| 5.1.4 Комбинированные признаки . . . . .               | 12        |
| 5.2 Обоснование выбора XGBoost . . . . .               | 12        |
| <b>6 Анализ результатов</b>                            | <b>13</b> |
| 6.1 Основные метрики оценки модели . . . . .           | 13        |
| 6.1.1 MAE (Mean Absolute Error) . . . . .              | 13        |

|           |  |           |
|-----------|--|-----------|
| 6.1.2     | RMSE (Root Mean Square Error) . . . . .    | 13        |
| 6.1.3     | $R^2$ (Коэффициент детерминации) . . . . . | 13        |
| 6.2       | Сравнение с базовой моделью . . . . .      | 14        |
| 6.2.1     | Видимое улучшение показателей . . . . .    | 14        |
| 6.2.2     | Распределение ошибок . . . . .             | 15        |
| 6.3       | Важность признаков . . . . .               | 15        |
| <b>7</b>  | <b>Выводы</b>                              | <b>16</b> |
| <b>8</b>  | <b>Возможные улучшения</b>                 | <b>17</b> |
| <b>9</b>  | <b>Полезные ссылки</b>                     | <b>18</b> |
| <b>10</b> | <b>Обзор литературы</b>                    | <b>18</b> |
|           | <b>Список литературы</b>                   | <b>19</b> |

## Аннотация

Прогресс аддитивных технологий (АМ) упростил разработку и изготовление инновационных и сложных конструкций или деталей, которые не могут быть получены методами традиционной вычитающей обработки. Чтобы обеспечить требуемый уровень функциональных характеристик конкретной детали, качество и процесс необходимо тщательно отслеживать, контролировать и оптимизировать с помощью продвинутых методов моделирования. Несмотря на эффективность существующих физически-ориентированных (physics-based) и основанных на данных (data-driven) методов, они имеют ограничения в обеспечении универсальности, интерпретируемости и точности для оптимизации и прогноза сложных процессов металлического аддитивного производства.

В данной работе рассматривается физически-информированное машинное обучение (Physics-Informed Machine Learning, PIML), которое является важным недавним достижением и предполагает встраивание физических знаний (например, термомеханических законов и ограничений) в модели машинного обучения (ML) с целью гарантировать надежность и интерпретируемость, а также повысить точность и эффективность прогнозов, устраняя при этом недостатки традиционных подходов.

## Ключевые слова

Машинное обучение, Аддитивное производство, Физически-информированное машинное обучение, Глубокие нейронные сети, Физически-информированные нейронные сети

# 1 Описание предметной области

Аддитивные технологии (АМ) в последние десятилетия стремительно развиваются благодаря превосходному потенциалу свободного формообразования по сравнению с традиционными методами вычитающей обработки. Они способны изготавливать сложные геометрии с меньшим расходом материала, способствуя устойчивому и эффективному производству в различных отраслях промышленности. Среди всех технологий АМ, металлическое аддитивное производство играет важную роль в высококачественном, индивидуализированном изготовлении деталей для аэрокосмической отрасли, стоматологии, медицины и других областей. Наиболее распространённые процессы металлического АМ включают Directed Energy Deposition (DED), Powder Bed Fusion (PBF) — включая Selective Laser Melting (SLM) и Electron Beam Melting (EBM) — и Binder Jetting. [1]

## 2 Анализ текущих проблем

### 2.1 Физически-ориентированные методы

В металлургическом АМ аналитические и численные физические модели находят широкое применение. Аналитические модели используются для оценки тепловых процессов и качества итогового изделия, учитывая такие эффекты, как теплопроводность, конвекцию и остаточные напряжения, однако они могут иметь ограничения, связанные с внесёнными упрощениями. Численные методы (CFD, FEA, FVM и др.) призваны компенсировать эти ограничения и способны моделировать сложные термомеханические явления, дополняя экспериментальные результаты для повышения точности. Практика совместного численного анализа и экспериментальной валидации доказала свою эффективность при рассмотрении термомеханического поведения, а также влияния параметров процесса.

Тем не менее, классические численные модели сталкиваются с вызовами при оценке прочности напечатанных деталей. Принятые в FEA допущения об однородности и изотропии становятся несостоятельными для деталей сложной формы, изготовленных методом АМ, так как их микроструктура может существенно отличаться от литых/прокатных аналогов. Это приводит к необходимости более адаптивных моделирующих подходов. Часто приходится использовать укрупнённые сетки и упрощённые модели из соображений вычислительной эффективности, что может негативно сказаться на точности. Дополнительная трудность здесь — рост размеров деталей, что делает затраты на расчёты чрезмерно высокими. По мере усложнения технологических процессов АМ, требований к крупногабаритной печати и по-

иску оптимальных параметров для обеспечения высокой плотности, перед исследователями встаёт задача преодоления ограничений вычислительных ресурсов. Таким образом, точное и оперативное прогнозирование в этой области остаётся серьёзным вызовом.

## 2.2 Методы, основанные на данных

Современные методы, основанные на данных, в частности, машинное обучение (ML), представляют собой альтернативу, позволяющую преодолеть ряд ограничений физически-ориентированных подходов. ML-технологии обрабатывают разнообразные данные: параметры процесса, термальные образы, временные ряды, акустические сигналы и измерения качества готовой детали. Это даёт возможность прогнозировать характеристики изделий или повышать эффективность производственных процессов путём анализа связей между некоторыми параметрами, которые нельзя легко учесть в классической модели.

Например, ML-модели, работающие с исходными изображениями (image-based), успешно применяются в металлургическом АМ для постоянного контроля и обнаружения аномалий. Среди них можно назвать глубокие нейронные сети (DNN), модели с долговременной краткосрочной памятью (LSTM) и «Случайный лес» (RF). Такая методика анализа визуальных данных (включая термограммы ванны расплава) позволяет осуществлять своевременное выявление дефектов. Кроме того, вибрационные сигналы также могут служить входными данными для ML-моделей (например, LSTM) с целью диагностики нештатных ситуаций.

Однако эффективность ML-моделей для предсказания и оптимизации в металлургическом АМ во многом зависит от доступности и качества данных. Помимо того, что эксперименты могут быть дорогими и трудоёмкими, на качество данных влияют неконтролируемые факторы (действия оператора, состояние оборудования, колебания среды) и случайные ошибки датчиков, что порождает неопределённость и может снижать точность моделей. Кроме того, в условиях производства небольших партий и индивидуальных заказов часто существует ограниченное количество размеченных данных, что усложняет обучение классических (полностью контролируемых) ML-подходов.

## 3 Обзор датасета

### 3.1 Введение

#### 3.1.1 Контекст исследования

Датасет представляет собой систематизированную коллекцию данных о производстве и характеристиках металлических образцов, созданных методом **Laser Metal Deposition (LMD)** - перспективной технологии аддитивного производства. Исследование фокусируется на взаимосвязи между технологическими параметрами процесса и результирующими механическими свойствами изделий из нержавеющей стали **316L**.

#### 3.1.2 Ценность датасета

- **Уникальность:** Комбинация данных реального производства с детальными измерениями механических свойств
- **Полнота:** Мультимодальные данные (параметры процесса, телеметрия, изображения, механические испытания)
- **Воспроизводимость:** Четкая документация методик и параметров

### 3.2 Экспериментальная методология

#### 3.2.1 Производственный процесс

##### Оборудование и материалы

- **Материал:** Нержавеющая сталь 316L (как основание, так и наплавляемый порошок)
- **Система LMD:** Роботизированная установка с порошковой подачей
- **Контрольные приборы:**
  - Термопары типа К с точностью  $\pm 1.5^{\circ}\text{C}$
  - Инфракрасная камера FLIR A655sc (640×480 пикселей, 50 Гц)

##### Вариации параметров

Таблица 3.1: Диапазоны варьируемых параметров

| Параметр              | Min | Max  | Единицы |
|-----------------------|-----|------|---------|
| Мощность лазера       | 800 | 2000 | Вт      |
| Скорость сканирования | 5   | 20   | мм/с    |
| Расход материала      | 5   | 15   | г/мин   |
| Количество слоев      | 15  | 45   | -       |




Рис. 3.1: Три стратегии планирования траектории с указанием порядка наплавки

### 3.2.2 Стратегии построения

- 1 **Стратегия 1:** Линейное сканирование с постоянным шагом
- 2 **Стратегия 2:** Шахматный порядок с чередованием направлений
- 3 **Стратегия 3:** Спиральная траектория от центра к периферии

## 3.3 Структура данных

### 3.3.1 Иерархия хранения

Dataset/

T1/

monitoring.hdf5

piece.jpg

crosssection.jpg

Testing/

coupon\_M.jpg

coupon\_I.jpg

coupon\_C.jpg



```

coupon_D.jpg
parameters.csv
coupons.csv
...
T37/

```

### 3.3.2 Форматы данных

#### HDF5-файлы

Таблица 3.2: Структура HDF5-файлов

| Группа       | Параметры                         | Описание                     |
|--------------|-----------------------------------|------------------------------|
| /data0       | timestamp, x, y, z, temp1...temp8 | Телеметрия робота и термопар |
| /image_data0 | image_id, x, y, z, image_data     | Термографические изображения |
| /features    | melpool_width, melpool_length...  | Расчетные характеристики     |

#### CSV-файлы

- **parameters.csv:**
  - 12 колонок с параметрами процесса
  - 37 строк (по одной на образец)
- **coupons.csv:**
  - 15 колонок с результатами испытаний
  - 148 строк (4 купона × 37 образцов)

## 3.4 Детальный анализ параметров

### 3.4.1 Технологические параметры

Таблица 3.3: Полный список параметров процесса

| Параметр                            | Тип                  | Описание                       |
|-------------------------------------|----------------------|--------------------------------|
| ID                                  | Категориальный       | Идентификатор образца (T1-T37) |
| Power [W]                           | Числовой             | Мощность лазера                |
| Speed [mm/s]                        | Числовой             | Скорость наплавки              |
| Strategy                            | Категориальный (1-3) | Стратегия сканирования         |
| Layer height [mm]                   | Числовой             | Средняя высота слоя            |
| Energy density [J/mm <sup>2</sup> ] | Числовой             | Расчетная плотность энергии    |

### 3.4.2 Механические свойства

Таблица 3.4: Измеряемые механические характеристики

| Параметр                | Обозначение | Метод испытания |
|-------------------------|-------------|-----------------|
| Предел текучести        | Rp0.2 [MPa] | ASTM E8/E8M     |
| Предел прочности        | Rm [MPa]    | ASTM E8/E8M     |
| Модуль упругости        | E [GPa]     | ASTM E111       |
| Относительное удлинение | A [%]       | ASTM E8/E8M     |
| Твердость по Виккерсу   | HV03        | ASTM E384       |

## 4 Постановка задачи и актуальность исследования

Проблема точного прогнозирования температуры зоны расплава (melt pool) в процессах лазерной обработки материалов является критически важной для современных аддитивных технологий. Нестабильность термических параметров приводит к дефектам микроструктуры, остаточным напряжениям и геометрическим искажениям готовых изделий. Традиционные методы контроля, основанные на термопарах и пирометрах, имеют существенные ограничения по пространственному разрешению и скорости отклика.

Разрабатываемая модель машинного обучения призвана решить следующие задачи:

- Прогнозирование средней температуры melt pool в реальном времени
- Выявление скрытых зависимостей между параметрами процесса и термическими характеристиками
- Оптимизация режимов обработки для предотвращения термических дефектов

## 5 Процесс обучения модели

### 5.1 Методы конструирования признаков

#### 5.1.1 Временные характеристики процесса

- Интервалы между измерениями:
  - `time_diff`: Разность временных меток между последовательными измерениями.
  - Метод расчета: `df.groupby('part_id')['timestamp'].diff().fillna(0)`.
  - Физический смысл: Базовая временная сетка для всех динамических расчетов.

- **Активное и пассивное время работы:**

- `t_laserON`: Время работы лазера (когда `process_status` = 1).
- **Расчет**: `time_diff * process_status`.
- `t_laserOFF`: Время простоя лазера (когда `process_status` = 0).
- **Расчет**: `time_diff * (1 - process_status)`.
- **Применение**: Учет термических инерционных эффектов.

### 5.1.2 Кинематические параметры

- **Перемещение по осям:**

- `delta_x, delta_y, delta_z`: Абсолютное изменение координат между измерениями.
- **Метод расчета**: Группировка по `part_id` с последующим дифференцированием.

- **Суммарное перемещение:**

- `movement_sum`: Сумма модулей перемещений по трем осям за `n_positions` точек.
- **Особенности**:
  - \* Скользящее окно из 3 позиций.
  - \* Групповой расчет по `part_id`.
- **Физический смысл**: Интегральная характеристика движения лазера.

### 5.1.3 Накопленные эффекты

- **Энергетические параметры:**

- `cumulative_energy`: Накопленное время работы лазера.
  - \* **Расчет**: Кумулятивная сумма `t_laserON` по группе `part_id`.
  - \* **Физическая интерпретация**: Прокси-переменная для накопленного тепла.

- **Параметры охлаждения:**

- `cumulative_cooling`: Накопленное время простоя.
  - \* **Расчет**: Кумулятивная сумма `t_laserOFF` по группе `part_id`.
  - \* **Значение**: Характеристика общего времени теплоотдачи.

#### 5.1.4 Комбинированные признаки

- **Взаимодействие стратегии и движения:**

- `strategy_movement`: Произведение типа стратегии на суммарное перемещение.
  - \* **Формула:** `Strategy * movement_sum`.
  - \* **Смысл:** Учет влияния стратегии на пространственное распределение энергии.

- **Энергетический вклад:**

- `energy_input`: Подведенная энергия за импульс.
  - \* **Расчет:** `Power * t_laserON`.
  - \* **Размерность:** Джоули (при мощности в Вт и времени в сек).

- **Скорость охлаждения:**

- `cooling_rate`: Изменение температуры в периоды простоя.
  - \* **Формула:**  $\Delta \text{meltpool\_mean} / (t_{\text{laserOFF}} + \epsilon)$ .
  - \* **Особенности:**
    - Использование малого  $\epsilon$  ( $1 \times 10^{-6}$ ) для избежания деления на 0.
    - Отрицательные значения соответствуют реальному охлаждению.

## 5.2 Обоснование выбора XGBoost

Для конкретного случая с использованием признаков `energy_input`, `cooling_rate` и `cumulative_energy` подходит модель XGBoost, так как имеет преимущества :

- 1 **Эффективно работает с нелинейными зависимостями:**

- Данные демонстрируют сложные физические взаимосвязи, включая:
  - Нелинейный рост между `Power` и `energy_input`.
  - Накопительный эффект между `cumulative_energy` и температурой.

- 2 **Обрабатывает смешанные типы признаков:**

- Непрерывные признаки: `Power`, `Speed`.
- Дискретные признаки: `Strategy`.
- Временные ряды: `cumulative_energy`, `movement_sum`.

### 3 Поддерживает интерпретируемость:

- Возможность анализа вклада каждого физического параметра.
- Определение ключевых факторов влияния на температуру.

## 6 Анализ результатов

### 6.1 Основные метрики оценки модели

#### 6.1.1 MAE (Mean Absolute Error)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **Описание:** Средняя абсолютная ошибка между фактическими ( $y_i$ ) и предсказанными ( $\hat{y}_i$ ) значениями.

#### 6.1.2 RMSE (Root Mean Square Error)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **Описание:** Корень из средней квадратичной ошибки.

#### 6.1.3 $R^2$ (Коэффициент детерминации)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- **Описание:** Доля дисперсии зависимой переменной, объяснённая моделью.
- **Сравнение метрик:**
  - MAE и RMSE оценивают ошибку в абсолютных величинах.
  - $R^2$  даёт относительную оценку качества модели.
  - Для комплексной оценки рекомендуется использовать несколько метрик.

Таблица 6.1: Сравнение показателей базовой и физической моделей

| Модель                   | MAE (C) | RMSE (C) | R <sup>2</sup> |
|--------------------------|---------|----------|----------------|
| Базовая модель           | 26.023  | 39.784   | 0.165          |
| Физическая модель (PIML) | 9.599   | 14.327   | 0.892          |

## 6.2 Сравнение с базовой моделью

### 6.2.1 Видимое улучшение показателей

- **MAE (Средняя абсолютная ошибка):** Физическая модель уменьшила ошибку прогноза температуры с 26°C до 9.6°C. Это особенно важно для процессов, требующих точного температурного контроля, таких как лазерная обработка материалов.
- **RMSE (Среднеквадратичная ошибка):** Снижение показателя с 39.8°C до 14.3°C свидетельствует о значительном уменьшении крупных отклонений, что критически важно для предотвращения перегревов.
- **R<sup>2</sup> (Коэффициент детерминации):** Рост с 0.165 (модель практически не объясняет данные) до 0.892 (высокая объясняющая способность) подтверждает, что физические признаки корректно отражают закономерности процесса.

Таблица 6.2: Улучшение метрик в процентах

| Метрика        | Улучшение (%) |
|----------------|---------------|
| MAE            | 63.1          |
| RMSE           | 64.0          |
| R <sup>2</sup> | 439.5         |




Рис. 6.1: Графики сравнений метрик

### 6.2.2 Распределение ошибок

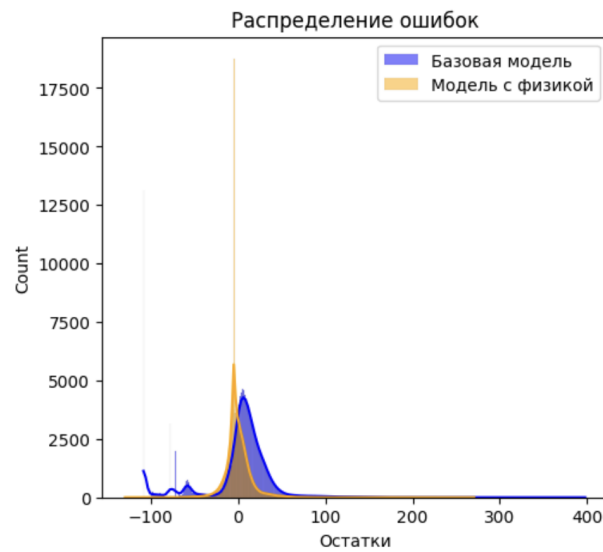



Рис. 6.2: Графики распределения ошибок

Таблица 6.3: Сравнение параметров распределения ошибок

| Параметр            | Базовая модель                   | Физическая модель (PIML) |
|---------------------|----------------------------------|--------------------------|
| Среднее остатков    | Близко к 0 (с систем. смещением) | 0 (несмещенная оценка)   |
| Дисперсия           | Высокая                          | Низкая                   |
| Форма распределения | Асимметрия, тяжёлые хвосты       | Близко к нормальному     |

### 6.3 Важность признаков



1 energy\_input (важность  $\sim 0.7$ )

- Главный определяющий фактор температуры расплава

- Прямая пропорциональность количеству передаваемой тепловой энергии
- Объясняет **70%** предсказательной способности модели

## 2 Strategy (важность $\sim 0.25$ )

- Вторая по значимости характеристика
- Определяет пространственное распределение энергии
- Различные стратегии (линейная, сетчатая, спиральная) формируют уникальные тепловые профили

## 3 cumulative\_cooling (важность $\sim 0.05$ )

- Относительно малый индивидуальный вклад
- Учитывает историю охлаждения материала

# 7 Выводы

Поставленная цель была достигнута - было показано, что PIML метод имеет ряд преимуществ против data-driven методов:

- **Снижение MAE на 63%:**
  - С  $26.0^{\circ}\text{C}$  до  $9.6^{\circ}\text{C}$
  - Позволяет добиться более точного контроля температурного режима
- **Увеличение  $R^2$  в 5.4 раза:**
  - С 0.165 до 0.892
  - Демонстрирует существенное улучшение объясняющей способности модели
- **Улучшение стабильности прогнозов:**
  - Снижение RMSE на 64%
  - Уменьшает вероятность крупных ошибок прогнозирования

На данный момент модель имеет ряд проблем, связанных с предсказанием высоких температур, которые могут оказаться критическими в реалиях производства.



## 8 Возможные улучшения

Стратегия прохода лазера в рамках нашей задачи играет одну из ключевых ролей, поэтому модели важно понимать в определенный момент, как движется лазер.

Исходя из важности признаков видно, что физическая фича `strategy_movement` не имеет никакой важности в помощи в предсказаниях для нашей модели. Эта фича может и дает нам какое-то понимание, но слишком проста в подсчете и не дает нужного результата.

Проблема заключается в том, что не так просто объяснить модели, как именно движется лазер в зависимости от стратегии. В идеале мы хотим, чтобы считались какие-то фичи, исходя из которых модели будет понятно, какая стратегия используется, поэтому давайте предложим некоторые physics-informed фичи, которые могут улучшить наши показатели:

$$\text{return\_time} = \Delta t_{\text{возврата}} = t_{\text{конец линии}} - t_{\text{начало след. линии}} \quad (1)$$

**Физический смысл:** Время переноса лазера между окончанием одного прохода и началом следующего. Критично для моделирования остывания материала в зоне, куда лазер возвращается.

**Решаемые проблемы:**

- Недоучет остывания материала во время переноса лазера
- Ложные предсказания температуры в начальных точках новых проходов

$$\text{cooling\_gradient} = \frac{\Delta T}{\text{return\_time} + \epsilon} \quad (2)$$

**Физический смысл:** Скорость остывания материала в точке во время отсутствия лазера.

**Особенности:**

- Учитывает нелинейность остывания (быстрее в начале, медленнее при приближении к температуре среды)

Вполне вероятно, что эти фичи добавят необходимое понимание стратегии для модели.

## 9 Полезные ссылки

Репозиторий: [ссылка на GitHub](#)

## 10 Обзор литературы

- 1 В работе Cao et al. [2] использовалась гауссова регрессия (Gaussian Process Regression) для прогноза шероховатости поверхности и точности размеров, которые затем применялись как целевые показатели для метода Whale Optimization Algorithm (WOA).
- 2 Kats et al. [3] разработали PIML-подход для управления режимами DED с целью формирования нужной зеренной микроструктуры, используя высокоточные численные данные, подтверждённые экспериментами. Их модель разбивала заготовку, полученную методом DED, на трёхмерные «кубики», оценивала градиенты температур и скорости охлаждения, а затем прогнозировала размер и соотношение сторон зёрен. Это дало возможность по термическому полю предсказать зеренную структуру.
- 3 Engelhardt et al. [4] использовали метод опорных векторов (Least Squares Support Vector Machine) для определения параметров, позволяющих получить детали с минимальной пористостью и высокой скоростью изготовления.
- 4 Wang et al. [5] выполнили оценку неопределённостей (uncertainty quantification) в металлургическом АМ на базе многофизических вычислительных моделей. Это уточнило понимание того, как варьирование параметров процесса влияет на материал, создав методологию для систематического учёта неопределённостей.

## Список литературы

- [1] Abdelrahman Farrag, Yuxin Yang, Nieqing Cao, Daehan Won и Yu Jin. “Physics-Informed Machine Learning for metal additive manufacturing”. В: (2024).
- [2] Cao L, Li J и Hu J. “Optimization of surface roughness and dimensional accuracy in LPBF additive manufacturing.” В: (2021). URL: <https://doi.org/10.1016/j.optlastec.2021.107246>.
- [3] Kats D, Wang Z и Gan Z. “A physics-informed machine learning method for predicting grain structure characteristics in directed energy deposition.” В: (2022). URL: <https://doi.org/10.1016/j.commatsci.2021.110958>.
- [4] Engelhardt A, Kahl M и Richter J. “Investigation of processing windows in additive manufacturing of AlSi10Mg for faster production utilizing data-driven modeling.” В: (2022). URL: <https://doi.org/10.1016/j.addma.2022.102858>.
- [5] Wang Z, Liu P и Ji Y. “ncertainty quantification in metallic additive manufacturing through physics-informed data-driven modeling.” В: (2019). URL: <https://doi.org/10.1007/s11837-019-03555-z>.